

RELATÓRIO FINAL — DESAFIO 07

Cancelamento de Reservas de Hotel

Curso	Inteligência Artificial — Classificadores
Grupo	7
Domínio	Hotelaria
Tipo	Classificação Binária
Dataset	jessemostipak/hotel-booking-demand
Entrega	19 de abril de 2026

Integrantes

Nome	RA
Kenji Yuri Mitsuka de Paula	2033472
Lucia Maria Reis Braga	2035292
Matheus Bargas Rodrigues Flausino	2057008

1. Objetivo

Prever se uma reserva de hotel será cancelada (**is_canceled**) com base em dados históricos. O modelo permite ao hotel implementar overbooking inteligente, políticas de depósito seletivas e ações de retenção, reduzindo prejuízos por cancelamentos de última hora.

2. Análise Exploratória (EDA)

Amostra utilizada: 10.000 registros (amostragem estratificada). Na primeira entrega o modelo foi treinado com apenas 2.000 registros, o que prejudicou os resultados — gráficos com menor incidência ficavam nulos e as métricas se tornavam instáveis. Após essa constatação, a amostra foi reajustada para 10.000 registros, resultando em distribuição mais representativa e métricas significativamente mais confiáveis.

2.1 Distribuição do dataset

Após o reajuste para 10.000 registros com amostragem estratificada, a distribuição das classes ficou proporcional ao dataset original:

Classe	Registros	Proporção
Reserva Mantida (0)	6.296	62,96 %
Reserva Cancelada (1)	3.704	37,04 %
Total	10.000	100 %

2.2 Cancelamentos por tipo de hotel

O **City Hotel** apresenta taxa de cancelamento de 41,9% (2.798 de 6.679 reservas), enquanto o **Resort Hotel** registra 27,3% (906 de 3.321 reservas), ficando abaixo da média geral. Isso indica que o perfil de cliente do City Hotel — geralmente viajantes corporativos ou de curta estadia — é mais propenso a cancelar.

2.3 Correlações com cancelamento (Pearson)

O gráfico de correlações revela as features numéricas mais associadas ao cancelamento:

Feature	Correlação	Interpretação
lead_time	+0,309	Quanto mais antecipada a reserva, maior o risco de cancelamento
total_of_special_requests	-0,228	Mais pedidos especiais → menor cancelamento (maior comprometimento)
required_car_parking_spaces	-0,195	Solicitação de estacionamento → tendência a manter a reserva
booking_changes	-0,139	Mais alterações na reserva → menor taxa de cancelamento
previous_cancellations	+0,108	Histórico de cancelamentos é preditor positivo relevante

2.4 Cancelamentos por tipo de depósito

O gráfico de features categóricas revela um padrão importante e contraintuitivo sobre o tipo de depósito:

Tipo de Depósito	Taxa de Cancelamento	Observação
Non Refund	99,4 %	Taxa quase total — clientes desistiram da viagem mesmo perdendo o depósito
No Deposit	28,2 %	Taxa próxima da média geral
Refundable	11,1 %	Menor taxa — garantia de devolução, mas reserva mantida na maioria dos casos

2.5 Cancelamentos por tipo de cliente

Clientes do tipo **Transient** apresentam a maior taxa de cancelamento (40,4%), acima da média geral. Já clientes do tipo **Group** cancelam apenas 13,2%, e clientes **Contract** registram 28,4%.

2.6 Feature Engineering

- **lead_time_faixa:** categorias 0–7d, 8–30d, 31–90d, 91–180d, 181–365d.
- **estação:** Primavera, Verão, Outono, Inverno — derivada do mês de chegada.
- **Imputação:** SimpleImputer com mediana para variáveis numéricas e moda para categóricas.
- **Encoding:** OneHotEncoder para variáveis de baixa cardinalidade (hotel, meal, market_segment, distribution_channel, deposit_type, customer_type, estacao).
- **Escalação:** StandardScaler nas variáveis numéricas.

3. Pré-processamento

Os dados foram divididos em **treino (70%)**, **validação (15%)** e **teste (15%)**, utilizando estratificação (*stratify=y*) para manter a mesma proporção de cancelamentos em todos os conjuntos.

A divisão 70/15/15 foi escolhida para garantir conjuntos de validação e teste com tamanho suficiente para avaliações estáveis. A estratégia 80/10/10 deixaria os conjuntos de validação e teste menores, tornando as métricas mais sensíveis a variações aleatórias.

Validação cruzada: Stratified K-Fold (k=5) aplicado sobre o conjunto combinado de treino e validação (8.500 amostras — 85% do total), e não apenas sobre o treino isolado. Isso garante uma avaliação robusta da estabilidade dos modelos antes da avaliação final no conjunto de teste.

4. Modelos Treinados

Foram treinados e comparados três classificadores com as mesmas partições de dados para garantir comparação justa:

Modelo	Configuração
Logistic Regression	Modelo linear utilizado como baseline
Random Forest	Ensemble de árvores de decisão (100 estimadores, max_depth=8)
Gradient Boosting	Boosting sequencial de árvores (100 estimadores, learning_rate=0,1, max_depth=4)

5. Resultados e Métricas

5.1 Comparativo geral

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	79,13 %	80,15 %	58,09 %	67,36 %	0,833
Random Forest	79,67 %	89,10 %	51,44 %	65,22 %	0,859
Gradient Boosting	80,80 %	81,60 %	62,23 %	70,61 %	0,866

5.2 Gradient Boosting — Detalhamento por classe (modelo escolhido)

Classe	Precisão	Recall	F1-Score	Suporte
Mantida	0,80	0,92	0,86	944
Cancelada	0,82	0,62	0,71	556
accuracy	—	—	0,81	1.500
macro avg	0,81	0,77	0,78	1.500
weighted avg	0,81	0,81	0,80	1.500

A validação cruzada Stratified K-Fold (k=5) sobre treino + validação (8.500 amostras) confirmou a estabilidade das métricas, sem sinais de overfitting.

6. Análise Comparativa

6.1 Qual modelo teve melhor desempenho? Por quê?

O **Gradient Boosting** obteve os melhores resultados em todas as métricas principais (F1-Score e AUC-ROC), superando os demais pelos seguintes motivos:

- **Capacidade não linear:** captura relações complexas entre features sem necessidade de transformações manuais.
- **Ensemble sequencial:** combina múltiplas árvores fracas de forma iterativa, corrigindo erros a cada etapa.
- **Robustez a outliers:** menos sensível a valores extremos em *lead_time*.

A Regressão Logística serve como excelente baseline — simples, interpretável e rápida — mas sua linearidade limita o poder preditivo em dados com relações complexas como este dataset.

6.2 Feature Importance — principais fatores de cancelamento

Os valores abaixo representam a **importância real das features no modelo Gradient Boosting**, expressos em percentual de contribuição para as decisões do modelo (soma = 100%):

Posição	Feature	Importância (GB)	Observação
1	deposit_type_Non Refund	46,34 %	Feature dominante — quase metade do poder preditivo do modelo
2	lead_time	12,35 %	Maior antecedência = maior risco de cancelamento

3	total_of_special_requests	7,82 %	Mais pedidos especiais = menor cancelamento
4	market_segment_Online TA	7,27 %	Reservas via agências online têm maior propensão a cancelamento
5	previous_cancellations	6,14 %	Histórico de cancelamentos é forte preditor positivo

*Nota: os valores de importância acima são os retornados pelo atributo **feature_importances_** do Gradient Boosting treinado, e diferem das correlações de Pearson reportadas na EDA — que medem associação linear simples, não contribuição preditiva do modelo.*

6.3 Aplicação de negócio — como o hotel pode usar essas previsões?

- **Overbooking inteligente:** aceitar reservas extras proporcionalmente ao nível de risco de cancelamento previsto pelo modelo.
- **Segmentação de risco:** reservas com alta probabilidade de cancelamento ($p > 0,7$) podem receber contato proativo de confirmação ou oferta de incentivo (upgrade, desconto).
- **Atenção ao deposit_type Non Refund:** embora intuitivamente pareçam seguras, reservas com depósito não reembolsável apresentaram taxa de cancelamento de 99,4% na amostra — o hotel deve investigar o perfil desses clientes e considerar políticas complementares.
- **Foco no lead_time:** reservas com alta antecedência merecem acompanhamento proativo, especialmente se combinadas com ausência de pedidos especiais.
- **Gestão de yield:** identificar janelas de alta propensão de cancelamento permite liberar quartos preventivamente para recomercialização.

7. Conclusão

O modelo de **Gradient Boosting** atingiu **80,8% de acurácia** e **AUC-ROC de 0,866**, fornecendo insights acionáveis para a operação hoteleira. A feature mais relevante para a previsão foi o **deposit_type Non Refund** (46,34% de importância no modelo), seguida pelo **lead_time** (12,35%) — que contrariamente ao esperado apresentou taxa de cancelamento de 99,4% para depósitos não reembolsáveis, exigindo investigação adicional sobre o perfil desses clientes.

O reajuste da amostra de 2.000 para 10.000 registros foi decisivo: gráficos antes nulos passaram a ter representatividade estatística, e as métricas tornaram-se mais estáveis e confiáveis.

A aplicação Streamlit desenvolvida permite que qualquer usuário, sem conhecimento técnico, preencha os dados de uma reserva e obtenha uma previsão em tempo real.

[Link do App: hotelcancelamentovscode-zp3jmgbh9jhnpwpw2daj8v.streamlit.app](https://hotelcancelamentovscode-zp3jmgbh9jhnpwpw2daj8v.streamlit.app)