

RELATÓRIO FINAL — DESAFIO 07

Cancelamento de Reservas de Hotel

Curso	Inteligencia Artificial — Classificadores
Grupo	7
Dominio	Hotelaria
Tipo	Classificacao Binaria
Dataset	jessemostipak/hotel-booking-demand
Entrega	19 de abril de 2026

Integrantes

Nome	RA
Kenji Yuri Mitsuka de Paula	2033472
Lucia Maria Reis Braga	2035292
Matheus Bargas Rodrigues Flausino	2057008

1. Objetivo

Prever se uma reserva de hotel será cancelada (**is_canceled**) com base em dados históricos. O modelo permite ao hotel implementar overbooking inteligente, políticas de depósito seletivas e ações de retenção, reduzindo prejuízos por cancelamentos de última hora.

Amostra utilizada: 10.000 registros (amostragem estratificada). Na primeira entrega o modelo foi treinado com apenas 2.000 registros, o que prejudicou os resultados gráficos com menor incidência ficavam nulos e as métricas RAM instáveis. Após essa constatação, a amostra foi reajustada para **10.000 registros**, resultando em distribuição mais representativa e métricas significativamente mais confiáveis.

2. Análise Exploratória (EDA)

2.1 Distribuição do dataset

Após o reajuste para 10.000 registros com amostragem estratificada, a distribuição das classes ficou proporcional ao dataset original:

Classe	Registros	Proporção
Reserva Mantida (0)	6.295	62,95 %
Reserva Cancelada (1)	3.705	37,05 %
Total	10.000	100 %

2.2 Cancelamentos por tipo de hotel

O **City Hotel** apresenta taxa de cancelamento de **41,9 %** (2.798 de 6.679 reservas), enquanto o **Resort Hotel** registra **27,3 %** (906 de 3.321 reservas), ficando abaixo da média geral. Isso indica que o perfil de cliente do City Hotel geralmente viajantes corporativos ou de curta estadia e mais propenso a cancelar.

2.3 Correlações com cancelamento (Pearson)

O gráfico de correlações revela as features numéricas mais associadas ao cancelamento:

- **lead_time** (+0,309): maior correlação positiva quanto mais antecipada a reserva, maior o risco de cancelamento.
- **total_of_special_requests** (-0,228): correlação negativa forte, clientes com mais pedidos especiais cancelam menos, indicando maior comprometimento.
- **required_car_parking_spaces** (-0,195): clientes que solicitam estacionamento tendem a manter a reserva.
- **booking_changes** (-0,139): reservas com mais alterações são menos canceladas.
- **previous_cancellations** (+0,108): histórico de cancelamentos e preditor positivo relevante.

2.4 Cancelamentos por tipo de depósito

O gráfico de features categóricas revela um padrão importante e contraintuitivo sobre o tipo de depósito:

- **Non Refund: 99,4 %** de cancelamento depósitos não reembolsáveis estão associados a taxa de cancelamento quase total. Clientes que pagaram um depósito irrecuperável frequentemente optam por cancelar mesmo assim, possivelmente por já terem desistido da viagem ou encontrado alternativas melhores.
- **No Deposit: 28,2 %** de cancelamento reservas sem depósito apresentam taxa próxima da média geral.
- **Refundable: 11,1 %** de cancelamento depósitos reembolsáveis apresentam a menor taxa, pois o cliente tem garantia de devolução caso precise cancelar, mas ainda assim mantém a reserva na maioria dos casos.

2.5 Cancelamentos por tipo de cliente

Clientes do tipo **Transient** apresentam a maior taxa de cancelamento (40,4 %), acima da média geral. Já clientes do tipo **Group** cancelam apenas 13,2 %, e clientes **Contract** registram 28,4 %.

2.6 Feature Engineering

- **lead_time_faixa**: categorias 0-7d, 8-30d, 31-90d, 91-180d, 181-365d.
- **estação**: Primavera, Verão, Outono, Inverno derivada do mês de chegada.

3. Pre-processamento

- **Imputação**: SimpleImputer mediana para variáveis numéricas, moda para categóricas.
- **Encoding**: OneHotEncoder para variáveis de baixa cardinalidade (hotel, meal, market_segment, distribution_channel, deposit_type, customer_type, estacao).
- **Escalonamento**: StandardScaler nas variáveis numéricas.
- **Divisão dos dados**: 70% para treino, 15% para validação e 15% para teste, utilizando estratificação (*stratify=y*) para manter a mesma proporção de cancelamentos em todos os conjuntos. A divisão 70/15/15 foi escolhida por oferecer um melhor equilíbrio entre treinamento e avaliação. Uma divisão 80/20/20 não foi utilizada porque a soma dos percentuais ultrapassaria 100% dos dados. Já a estratégia 80/10/10 deixaria os conjuntos de validação e teste menores, tornando as métricas mais sensíveis a variações aleatórias. Dessa forma, a divisão 70/15/15 permite treinar os modelos com uma quantidade adequada de dados e, ao mesmo tempo, realizar avaliações mais confiáveis.
- **Validação cruzada**: Stratified K-Fold (k=5).

4. Modelos Treinados

Foram treinados e comparados três classificadores com as mesmas partições de dados para garantir comparação justa:

- **Logistic Regression** — modelo linear utilizado como baseline.
- **Random Forest** — ensemble de árvores de decisão (100 estimadores, max_depth=8).
- **Gradient Boosting** — boosting sequencial de árvores (100 estimadores, learning_rate=0,1, max_depth=4).

5. Resultados e Metricas


5.1 Comparativo geral

Modelo	Acuracia	Precisao	Recall	F1-Score	AUC-ROC
Logistic Regression	79,13 %	80,15 %	58,09 %	67,36 %	0,833
Random Forest	79,67 %	89,10 %	51,44 %	65,22 %	0,859
Gradient Boosting	80,80 %	81,60 %	62,23 %	70,61 %	0,866

5.2 Gradient Boosting — Detalhamento por classe (modelo escolhido)

Classe	Precisao	Recall	F1-Score	Suporte
Mantida	0,80	0,92	0,86	944
Cancelada	0,82	0,62	0,71	556

5.3 Curvas ROC — Comparação de Modelos



6. Análise Comparativa

6.1 Qual modelo teve melhor desempenho? Porquê?

O **Gradient Boosting** obteve os melhores resultados em todas as métricas principais (F1-Score e AUC-ROC), superando os demais pelos seguintes motivos:

- **Capacidade Não linear:** captura relações complexas entre features sem necessidade de transformações manuais.
- **Ensemble sequencial:** combina múltiplas árvores fracas de forma iterativa, corrigindo erros a cada etapa.
- **Robustez a outliers:** menos sensível a valores extremos em `lead_time`.

A Regressão Logística serve como excelente baseline — simples, interpretável e rápida — mas sua linearidade limita o poder preditivo em dados com relações complexas como este dataset.

6.2 Feature Importance — principais fatores de cancelamento

Posicao	Feature	Influencia
1	<code>lead_time</code> (+0,309)	Maior antecedência = maior risco de cancelamento
2	<code>deposit_type Non Refund</code> (99,4%)	Associado a taxa de cancelamento quase total
3	<code>total_of_special_requests</code> (-0,228)	Mais pedidos especiais = menor cancelamento
4	<code>required_car_parking</code> (-0,195)	Solicitação de estacionamento reduz cancelamento
5	<code>previous_cancellations</code> (+0,108)	Histórico de cancelamentos e forte preditor

6.3 Aplicação de negócio — como o hotel pode usar essas previsões?

- **Overbooking inteligente:** aceitar reservas extras proporcionalmente ao nível de risco de cancelamento previsto pelo modelo.
- **Segmentação de risco:** reservas com alta probabilidade de cancelamento ($p > 0,7$) podem receber contato proativo de confirmação ou oferta de incentivo (upgrade, desconto).
- **Atenção ao `deposit_type Non Refund`:** embora intuitivamente pareçam seguras, reservas com depósito não reembolsável apresentaram taxa de cancelamento de 99,4 % na amostra — o hotel deve investigar o perfil desses clientes e considerar políticas complementares.
- **Foco no `lead_time`:** reservas com alta antecedência merecem acompanhamento proativo, especialmente se combinadas com ausência de pedidos especiais.
- **Gestão de yield:** identificar janelas de alta propensão de cancelamento permite liberar quartos preventivamente para recomercialização.

7. Conclusão

O modelo de **Gradient Boosting** atingiu **80,8 % de acurácia** e **AUC-ROC de 0,866**, fornecendo insights acionáveis para a operação hoteleira. O principal driver de cancelamento é o **`lead_time`** (correlação +0,309), seguido pelo comportamento atípico do **`deposit_type Non Refund`** — que contrariamente ao esperado apresentou taxa de cancelamento de 99,4 %, exigindo investigação

adicional sobre o perfil desses clientes.

O reajuste da amostra de 2.000 para **10.000 registros** foi decisivo: gráficos antes nulos passaram a ter representatividade estatística, e as métricas tornaram-se mais estáveis e confiáveis.

A aplicação Streamlit desenvolvida permite que qualquer usuário, sem conhecimento técnico, preencha os dados de uma reserva e obtenha uma previsão em tempo real.

Link do App Publicado

<https://hotelcancelamentovscode-zp3jmgbh9jhnpwpw2daj8v.streamlit.app/>
